Prediksi harga mobil bekas menggunakan Machine Learning terhadap situs jual-beli mobil bekas.

Syarah.com

DISUSUN OLEH :
SADDAM FACHRIZA YUSUF

1. Gambaran Umum
2. Pemahaman Data
3. Modelling
4. Kesimpulan & Rekomendasi

Company Overview

About the Company

Syarah adalah platform digital untuk jual beli mobil bekas di Arab Saudi yang menghubungkan penjual dengan pembeli kendaraan. Syarah.com menyediakan pelayanan optimal pada situs dan aplikasi yang mereka kembangkan, seperti berbagai jenis dan merek mobil, variasi harga, serta lokasi kendaraan yang dapat diakses melalui platform resmi. Konsumen yang mengakses situs Syarah.com memperoleh data lengkap mengenai semua kendaraan yang ada di situs dan aplikasi.

Company Overview

Stakeholders

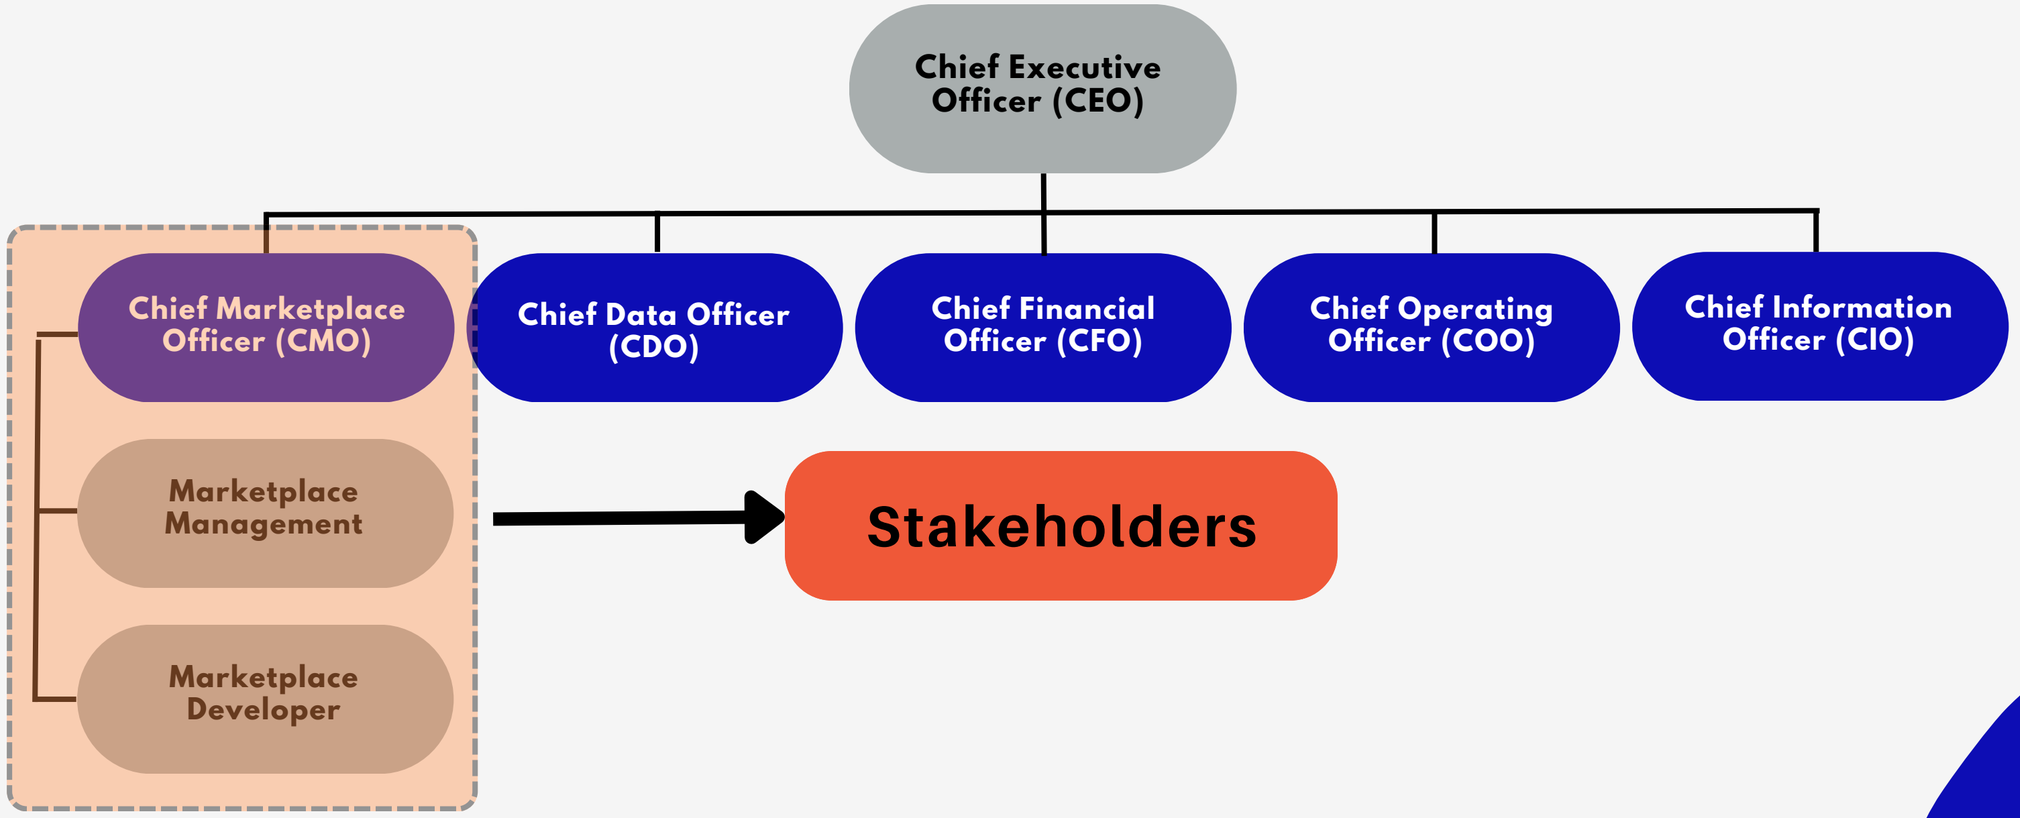

Company Overview

Promblem Statement

Marketplace mobil bekas seperti Syarah pastinya memiliki permasalahan, salah satunya adalah proses penentuan harga kendaraan. Ketidaktepatan dalam menetapkan acuan harga berpotensi menyebabkan kendaraan terlalu mahal sehingga sulit terjual, atau terlalu murah sehingga merugikan penjual. Kondisi ini tidak hanya mempengaruhi efisiensi waktu terhadap pemilihan harga, tetapi juga berdampak pada dan performa bisnis marketplace secara keseluruhan.

Goals

Membangun model machine learning yang mampu memprediksi harga mobil bekas berdasarkan karakteristik kendaraan, sehingga dapat digunakan sebagai sistem rekomendasi harga yang membantu seller menetapkan harga yang optimal dan kompetitif.

Analytical Approach

pendekatan yang digunakan dalam proyek ini adalah supervised machine learning dengan metode regresi. Tahapan analisis dimulai dari eksplorasi data, kemudian dilanjutkan dengan proses data preprocessing seperti encoding dan scaling, serta feature engineering. Selanjutnya dilakukan proses pemodelan dengan membandingkan beberapa algoritma regresi untuk menemukan model dengan performa terbaik. Setelah model terbaik diperoleh, dilakukan hyperparameter tuning guna mengoptimalkan performa serta mengurangi risiko overfitting.

Data Understanding

Categorical Column

Type : Type of car
Region : Region in which the used car was offered for sale.
Make : The car brand
Gear_Type : Gear type of the car (Automatic/Manual)
Origin : Origin of the car
Options : Option of the car (Standard, Semi-Full, Full)

Numerical Column

Year : Manufacturing Year
Engine_Size : Size of the car engine
Mileage : Mileage of car
Negotiable : Can be negotiable or not
Price : Price of the car

Data Cleaning

DATA GRUP	COLUMN	METHOD
NUMERICAL COLUMN	NEGOTIABLE	DROP COLUMN
	YEAR, ENGINE SIZE	DROP ANOMALIES
	MILEAGE, PRICE	
	CAR AGE	DEFINE FROM CURENT YEAR (2026) & YEAR COLUMN
	CAR MILEAGE	DEFINE FROM MILEAGE / YEAR COLUMN

Data Preprocessing

PREPROCESSING	COLUMN
ONE HOT ENCODER	GEAR TYPE, ORIGIN, OPTIONS
BINARY ENCODER	TYPE, REGION, MAKE
ROBUST SCALER	YEAR, CAR AGE, ENGINE SIZE, MILEAGE, MILEAGE PER YEAR, PRICE

BEST MODEL BRANCHMARKING

XGBOOST REGRESSOR
WITH HYPERPARAMETER TUNING

Hyperparameter Tuning

XGBOOST REGRESSOR WITH HYPERPARAMETER TUNING

MAX DEPTH	3
LEARNING RATE	0.01, 0.02
N ESTIMATOR	300
SUBSAMPLE	0.7
COLSAMPLE BY TREE	0.7
GAMMA	5, 6, 7, 8, 9, 10
REG ALPHA	8, 10
REG LAMBDA	8, 10

EVALUATIOIN

Score Before Tuning

RMSE	20902.53
MAE	13252.74
MAPE	1.28

Score After Tuning

RMSE	23327.55
MAE	15877.50
MAPE	1.47

Performance Comparison

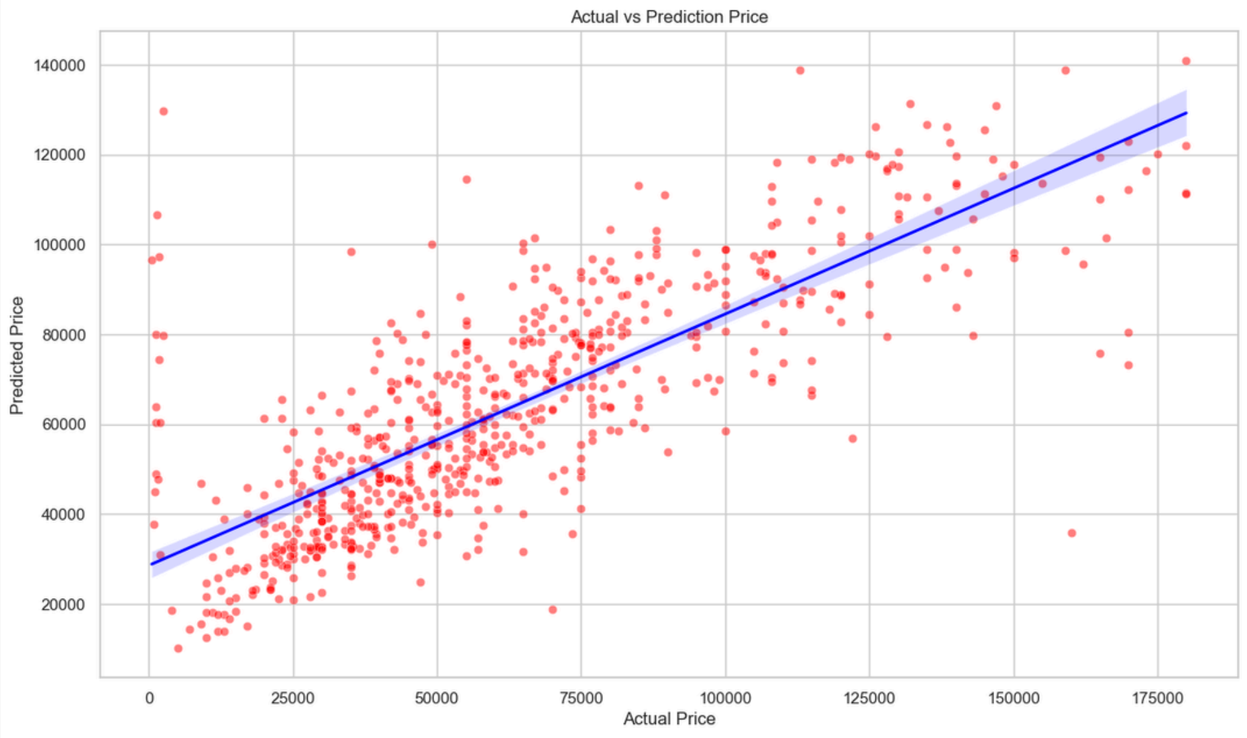

- Model menunjukkan hubungan linear positif yang kuat antara harga aktual dan prediksi, yang menandakan bahwa model mampu menangkap tren harga secara umum.
- Error prediksi meningkat pada level harga yang lebih tinggi, yang mengindikasikan adanya heteroskedastisitas dalam model.
- Model cenderung sedikit meng-underestimate kendaraan dengan harga tinggi, yang menunjukkan keterbatasan sensitivitas pada segmen pasar premium.

Conclusion

Model machine learning berbasis XGBoost Regressor menunjukkan performa yang cukup baik dalam memprediksi nilai target dengan tingkat error yang relatif rendah (RMSE 6,32%). Perbedaan RMSE antara data train dan test yang tidak terlalu jauh mengindikasikan bahwa model cukup stabil dan tidak mengalami overfitting yang signifikan.

Hasil benchmarking menempatkan XGBoost sebagai algoritma terbaik dibandingkan model lain, bahkan model baseline memberikan performa yang lebih optimal dibandingkan hasil hyperparameter tuning. Meskipun demikian, model masih memiliki keterbatasan dalam memprediksi nilai pada rentang tinggi akibat adanya indikasi heteroskedasticity.

Secara keseluruhan, model sudah cukup robust dan layak digunakan sebagai baseline, namun masih memiliki ruang pengembangan untuk meningkatkan akurasi pada nilai ekstrem dan mengurangi variasi error.

Recommendation

Berdasarkan hasil diatas, terdapat beberapa rekomendasi yang dapat dilakukan untuk pengembangan lebih lanjut adalah sebagai berikut:

1. **Model Improvement**
   - Menerapkan transformasi pada variabel target, seperti log transformation, untuk mengurangi skewness dan mengatasi heteroskedasticity
   - Mengeksplorasi algoritma lain yang lebih adaptif terhadap distribusi data kompleks, seperti LightGBM atau CatBoost
   - Melakukan tuning hyperparameter dengan ruang pencarian yang lebih luas dan terarah

2. **Data Cleaning**
   - Melakukan feature selection untuk mengurangi noise dan meningkatkan interpretabilitas model

3. **Error & Data Handling**
   - Melakukan analisis lebih lanjut terhadap outlier, khususnya pada nilai target tinggi
   - Menggunakan pendekatan robust modeling untuk mengurangi sensitivitas terhadap data ekstrem
   - Mengevaluasi distribusi residual untuk memastikan asumsi model lebih terpenuhi

Terima Kasih